

Informe de Laboratorio: Transfer Learning con VGG16 y CIFAR-10

Gabriel Paz Diedrich Solis

2 de noviembre

Resumen

Este informe evalúa el desempeño del modelo preentrenado VGG16 en el dataset CIFAR-10 bajo tres configuraciones diferentes: sin entrenamiento adicional, feature extraction y fine-tuning. Los resultados muestran mejoras significativas en precisión al aplicar transfer learning, alcanzando un 93.33 % de precisión en el conjunto de prueba con fine-tuning.

1. Introducción

El aprendizaje por transferencia (transfer learning) es una técnica que aprovecha conocimientos de un modelo preentrenado en un problema similar. En este trabajo utilizamos la arquitectura VGG16 preentrenada en ImageNet y la adaptamos al dataset CIFAR-10.

1.1. Arquitectura VGG16

- 16 capas con pesos (13 convolucionales + 3 fully connected)
- Entrada esperada: 224×224 píxeles RGB
- Preentrenada en ImageNet (1.2M imágenes, 1000 clases)
- Aproximadamente 138 millones de parámetros

1.2. Dataset CIFAR-10

- 60,000 imágenes 32×32 píxeles RGB
- 10 clases diferentes
- División: 50,000 entrenamiento / 10,000 prueba

2. Metodología

2.1. Preprocesamiento de Datos

- Redimensionamiento a 224×224 píxeles
- Normalización usando estadísticas de ImageNet
- Data augmentation (volteo horizontal) para entrenamiento
- División: 90 % entrenamiento (45,000), 10 % validación (5,000)

2.2. Configuraciones Experimentales

2.2.1. Baseline: Sin entrenamiento adicional

- Última capa reemplazada por capa lineal con 10 salidas
- Evaluación directa sin ajuste de pesos

2.2.2. Feature Extraction

- Capas convolucionales congeladas
- Solo se entrena la última capa del clasificador
- Learning rate: $1e-4$
- Épocas: 8

2.2.3. Fine-Tuning

- Todas las capas entrenables
- Learning rate reducido: $1e-5$
- Épocas: 8
- Scheduler: StepLR ($\gamma=0.8$ cada 3 épocas)

3. Resultados

3.1. Métricas de Evaluación

Cuadro 1: Comparación de Resultados en Test

Configuración	Pérdida	Precisión	Mejor Val. Acc.
Baseline	2.3840	5.92 %	-
Feature Extraction	0.4876	83.22 %	83.48 %
Fine-Tuning	0.1973	93.33 %	94.20 %

3.2. Análisis de Curvas de Aprendizaje




Figura 1: Precisión vs Época - Feature Extraction

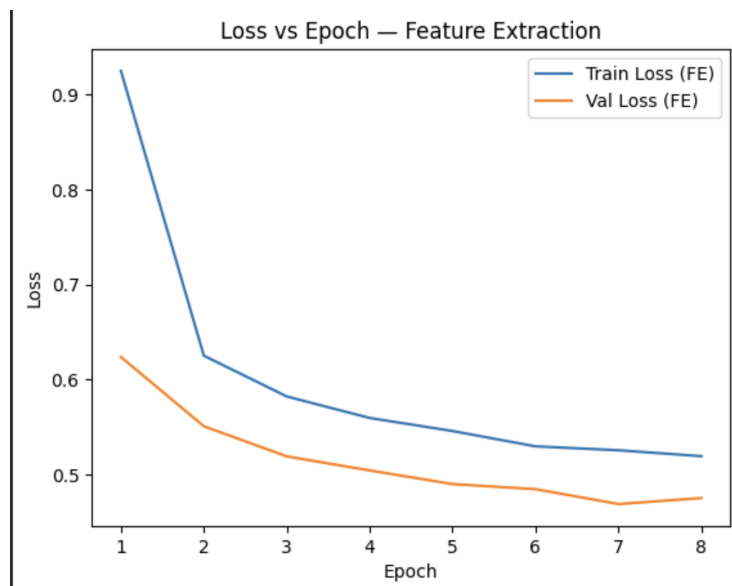


Figura 2: Pérdida vs Época - Feature Extraction

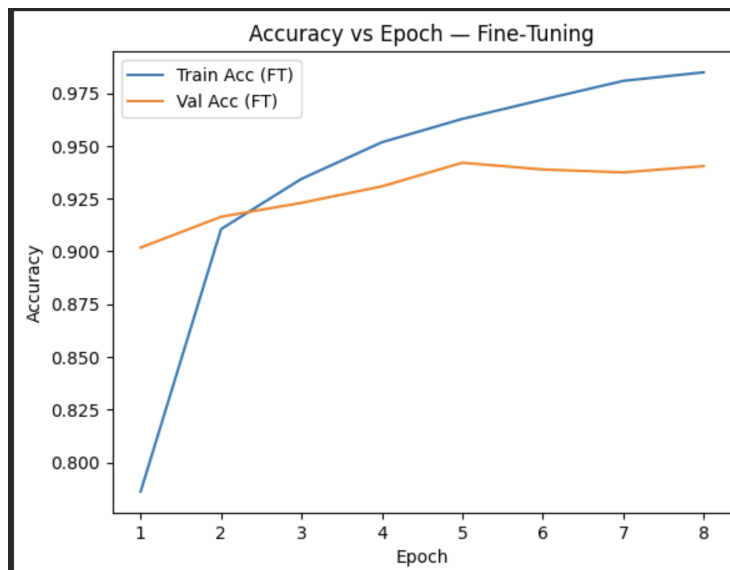


Figura 3: Precisión vs Época - Fine-Tuning

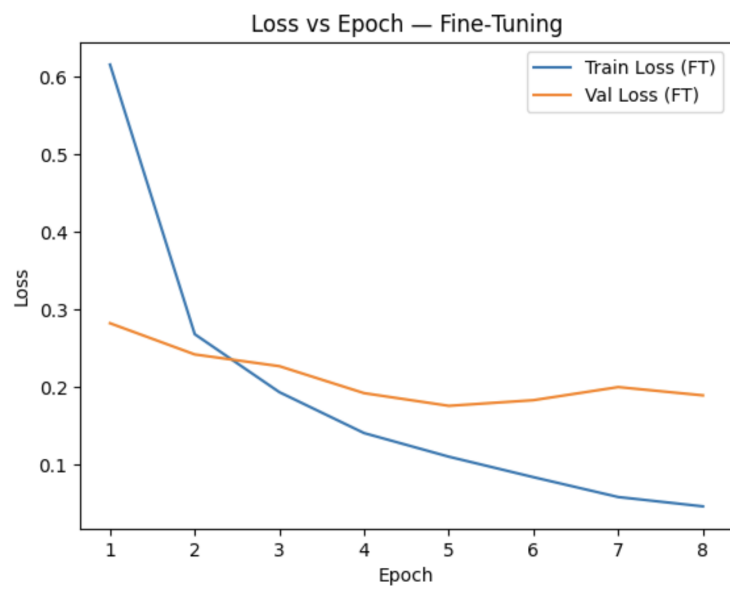


Figura 4: Pérdida vs Época - Fine-Tuning

4. Discusión

4.1. Análisis Comparativo

- **Baseline:** El bajo rendimiento (5.92 %) confirma que el modelo preentrenado no generaliza bien sin adaptación
- **Feature Extraction:** Mejora significativa (83.22 %) demostrando la utilidad de las características aprendidas
- **Fine-Tuning:** Máximo rendimiento (93.33 %) al permitir ajustes en todas las capas

4.2. Observaciones Técnicas

- El fine-tuning requiere más tiempo de cómputo pero ofrece mejor rendimiento
- La precisión de validación y prueba son consistentes, indicando buen ajuste
- El learning rate reducido en fine-tuning previene sobreajuste

5. Conclusiones

- El transfer learning es efectivo para adaptar VGG16 a CIFAR-10
- Feature extraction proporciona mejoras rápidas con menos recursos
- Fine-tuning maximiza el rendimiento pero requiere más cómputo
- La metodología demostró ser reproducible y efectiva
- Los resultados validan la utilidad del aprendizaje por transferencia en visión por computadora

Repositorio

El código completo está disponible en: <https://github.com/gabrielpaz2003/Laboratorio8Deeplearning.git>